

Link prediction in una rete sociale con GNN

Obiettivi

Affrontare il task di link prediction su una rete sociale o di co-autoraggio: dato un grafo parzialmente osservato, predire la presenza di archi mancanti o futuri. Lo studente dovrà implementare baseline classiche basate su euristiche locali (Common Neighbors, Jaccard, Adamic-Adar, Preferential Attachment) e confrontarle con approcci di tipo GNN encoder + decoder (es. GraphSAGE + dot product, GAE/VGAE).

Attività principali

- Costruzione del dataset di link positivi/negativi con sampling controllato.
- Implementazione delle baseline euristiche con NetworkX.
- Implementazione di un encoder GNN che produce embedding di nodi, e di un decoder per la probabilità di esistenza dell'arco.
- Valutazione con AUC, AP, Hits@k.
- Discussione delle implicazioni etiche (link prediction in social network e privacy).

Tecnologie suggerite

Python, PyTorch, PyTorch Geometric, NetworkX, scikit-learn.

Dataset

- **Facebook Social Circles (SNAP):** <https://snap.stanford.edu/data/ego-Facebook.html>. Rete sociale anonimizzata.
- **ca-AstroPh / ca-GrQc (SNAP):** <https://snap.stanford.edu/data/>. Reti di co-autoraggio scientifico.
- **ogbl-ddi o ogbl-collab (OGB):** alternative pulite e standardizzate per il benchmarking.

Estensioni opzionali

- Estensione del problema a grafi temporali (link prediction dinamica).
- Valutazione del bias del modello rispetto a nodi a basso e alto grado.

Tutti i progetti dovranno essere consegnati come repository Git ben strutturato, contenente: codice Python modulare, un file README con istruzioni di esecuzione, un notebook Jupyter con l'analisi esplorativa e i risultati principali, una relazione tecnica (massimo 15 pagine) che descriva il problema, le scelte progettuali, gli esperimenti e una discussione critica dei risultati. È fortemente consigliato l'uso di ambienti virtuali (venv, conda) e di un file requirements.txt o environment.yml per la riproducibilità.

La valutazione terrà conto della correttezza tecnica, della qualità del codice, della rigorousità sperimentale e della chiarezza della discussione critica dei risultati.